

Relatorio Tecnico Consolidado - AG, API, LLM e Avaliacao

1. Escopo da Entrega

Esta entrega cobre cinco frentes integradas:

1. implementacao do Algoritmo Genetico (AG) para otimizacao de hiper-parametros;
2. exportacao produtiva dos melhores artefatos para a API;
3. testes automatizados do nucleo do AG e da API;
4. resiliencia do cliente Gemini com controle de chamadas e tratamento de falhas 429;
5. avaliacao da qualidade das interpretacoes geradas pela LLM.

2. Arquivos Canonicos da Solucao

2.1 Codigo

- `train_model/genetic_optimizer.py`: AG tabular para classificadores sklearn.
- `train_model/genetic_optimizer_image.py`: AG para o fluxo de visao computacional.
- `backend/main.py`: carga dos artefatos produtivos e endpoints da API.
- `backend/llm/interpreter.py`: prompts, retries, fallback e integracao Gemini.
- `tests/test_genetic_optimizer.py`: testes do AG tabular.
- `tests/test_genetic_optimizer_image.py`: testes leves do AG de imagem.
- `tests/test_api.py`: testes automatizados da API tabular.

2.2 Artefatos Gerados

- `train_model/ga_optimization_results.json`
- `train_model/ga_image_optimization_results.json`
- `backend/model/lung_cancer_classifier.joblib`
- `backend/model/lung_cancer_classifier.metadata.json`
- `backend/model/best.keras`
- `backend/model/best_info.json`
- `backend/model/metrics.json`

3. Arquitetura Integrada

flowchart TB

```
subgraph TAB["Treinamento Tabular"]
    A1[Dataset tabular CSV]
    A2[genetic_optimizer.py]
```

```

    A3[Split 60/20/20 + preprocessamento]
    A4[AG em 4 modelos]
    A5[Ranking e melhor configuracao]
    A6[Export lung_cancer_classifier.joblib + metadata]
    A1 --> A2 --> A3 --> A4 --> A5 --> A6
end

subgraph IMG["Treinamento de Imagem"]
    B1[Dataset IQ-OTH NCCD]
    B2[genetic_optimizer_image.py]
    B3[Split treino validacao teste]
    B4[AG para hiperparametros CNN]
    B5[Melhor threshold + metricas]
    B6[Export best.keras + metrics.json]
    B1 --> B2 --> B3 --> B4 --> B5 --> B6
end

subgraph ART["Artefatos Produtivos"]
    C1[backend/model]
end

subgraph API["Backend e Consumo"]
    D1[backend/main.py]
    D2[/analyze-tabular/]
    D3[/analyze-images/]
    D4[frontend/app.py]
    D1 --> D2
    D1 --> D3
    D4 --> D1
end

subgraph LLM["Interpretacao por LLM"]
    E1[backend/llm/interpreter.py]
    E2[Prompts estruturados]
    E3[Limite de chamadas]
    E4[Retry 429 + fallback]
    E1 --> E2
    E1 --> E4
end

subgraph TEST["Validacao"]
    F1[test_genetic_optimizer.py]
    F2[test_genetic_optimizer_image.py]
    F3[test_api.py]
end

```

```

A6 --> C1
B6 --> C1
C1 --> D1
D2 --> E1
D3 --> E1
E3 -. politica aplicada em .-> D2
E3 -. politica aplicada em .-> D3
F1 --> A2
F2 --> B2
F3 --> D1

```

4. Logica e Estrutura do Algoritmo Genetico

4.1 Fluxo tabular

O AG tabular foi implementado em `train_model/genetic_optimizer.py` para quatro classificadores:

- `RandomForestClassifier`
- `LogisticRegression`
- `KNeighborsClassifier`
- `ExtraTreesClassifier`

Estrutura do processo:

1. carregar o dataset tabular e realizar split 60/20/20;
2. construir pipeline com processamento sklearn;
3. definir espaco de busca por modelo;
4. gerar populacao inicial aleatoria;
5. avaliar individuos com funcao de fitness orientada a recall, especificidade, F1 e penalidade de fairness;
6. aplicar selecao por torneio, crossover uniforme, mutacao e elitismo;
7. consolidar o melhor individuo por experimento;
8. exportar o melhor artefato produtivo para `backend/model/lung_cancer_classifier.joblib`.

Funcao de fitness tabular:

```
fitness = 0.6 * recall + 0.2 * specificity + 0.2 * f1 - 0.5 * fairness_penalty
```

Com:

- `fairness_penalty = max(recall_por_grupo) - min(recall_por_grupo)`
- grupo monitorado: GENDER

4.2 Fluxo de imagem

O AG de imagem foi implementado em `train_model/genetic_optimizer_image.py` para ajustar o treinamento de uma CNN baseada em `EfficientNetB0`.

Hiperparametros pesquisados:

- `learning_rate`
- `batch_size`
- `frozen_epochs`
- `fine_tune_epochs`
- `dense_units`
- `dropout_rate`
- `use_class_weight`
- `unfreeze_layers`

Fluxo resumido:

1. extrair o dataset IQ-OTH/NCCD;
2. construir splits de treino, validacao e teste;
3. treinar candidatos com congelamento inicial e fine-tuning controlado;
4. escolher o melhor threshold no conjunto de validacao;
5. avaliar no conjunto de teste;
6. calcular fitness orientado a `recall`, `specificity`, `f1` e `auc_roc`;
7. exportar o melhor modelo para `backend/model/best.keras`.

Funcao de fitness de imagem:

`fitness = 0.45 * recall + 0.20 * specificity + 0.20 * f1 + 0.15 * auc_roc`

5. Configuracao Experimental

5.1 Tabular

Dataset tabular:

- total: 3000 amostras
- treino: 1800
- validacao: 600
- teste: 600

Experimentos executados:

Experimento	Populacao	Geracoes	Crossover	Mutacao	Seed
exp1	8	3	0.8	0.1	1
exp2	8	3	0.8	0.3	2
exp3	12	3	0.8	0.1	3

5.2 Imagem

Dataset de imagem:

- total: 1097 imagens
- treino: 767
- validacao: 165
- teste: 165

Experimentos executados:

Experimento	Populacao	Geracoes	Crossover	Mutacao	Seed
exp1	2	1	0.8	0.15	11
exp2	2	1	0.8	0.30	22
exp3	3	2	0.8	0.20	33

6. Resultados Consolidados do AG Tabular

6.1 Ranking final

Posicao	Modelo	Melhor experimento	Fitness
1	RandomForestClassifier	exp3	0.5551
2	KNeighborsClassifier	exp2	0.5456
3	LogisticRegression	exp3	0.5119
4	ExtraTreesClassifier	exp3	0.5073

Melhor modelo global:

- modelo: `RandomForestClassifier`
- experimento vencedor: `exp3`
- fitness de validacao: 0.5550641876345416

6.2 Melhores hiperparametros por modelo

`RandomForestClassifier`

```
{  
  "n_estimators": 221,  
  "max_depth": 27,  
  "min_samples_split": 3,  
  "min_samples_leaf": 2,  
  "max_features": 0.8308  
}
```

`KNeighborsClassifier`

```
{  
  "n_neighbors": 9,  
  "weights": "uniform",  
  "p": 2  
}
```

`LogisticRegression`

```
{
  "C": 0.1613,
  "penalty": "l1",
  "solver": "saga",
  "class_weight": None,
  "max_iter": 256
}
```

ExtraTreesClassifier

```
{
  "n_estimators": 118,
  "max_depth": 18,
  "min_samples_split": 3,
  "min_samples_leaf": 1,
  "max_features": 0.9362
}
```

7. Comparativo de Performance - Original vs Otimizado via AG

As metricas desta secao consolidam a comparacao entre os modelos em configuracao original e suas melhores configuracoes encontradas pelo AG. Os dados foram extraidos do fluxo comparativo documentado em `train_model/ag_analise_cancer.ipynb`.

Modelo	Original			AG			Delta			Original			AG			Delta			Melhor exp
	acc	acc	acc	re- call	re- call	re- call	spec	spec	spec	F1	F1	F1	F1	F1	F1	F1	F1	F1	
RandomForestClassifier	0.5675	0.5675	0.5675	0.6549	0.6549	0.6086	0.0592	0.2523	0.4865	0.0302	0.2545	0.5772	0.0345	0.2545	0.5772	0.0345	0.2545	0.5772	3p3
LogisticRegression	0.5200	0.5180	0.0000	0.7582	0.5694	0.0132	0.4560	0.4662	0.0101	0.1551	0.5449	0.0065	0.1551	0.5449	0.0065	0.1551	0.5449	0.0065	2p2
KNeighborsClassifier	0.5050	0.5030	0.0000	0.7516	0.5263	0.0099	0.4932	0.4797	0.0103	0.5513	0.5178	0.0082	0.5513	0.5178	0.0082	0.5513	0.5178	0.0082	3p3
ExtraTreesClassifier	0.5410	0.5230	0.0000	0.3539	0.5362	0.0035	0.2336	0.5104	0.0103	0.5538	0.5327	0.0052	0.5538	0.5327	0.0052	0.5538	0.5327	0.0052	3p3

Leitura tecnica:

- o **RandomForestClassifier** foi o modelo com ganho mais claro apos otimizacao, melhorando **accuracy**, **recall** e **F1**;
- o **KNeighborsClassifier** manteve desempenho competitivo e apresentou a menor penalidade de fairness na validacao (0.0011);
- LogisticRegression** e **ExtraTreesClassifier** nao superaram seus base-lines em todas as metricas, o que reforca que o AG deve ser analisado por objetivo clinico e nao apenas por acuracia isolada;
- o criterio de selecao final priorizou sensibilidade e equilibrio de fairness, nao apenas a melhor pontuacao de teste.

8. Artefato Tabular Exportado para Uso Produtivo

O AG exportou automaticamente o melhor pipeline tabular para a API:

- artefato: `backend/model/lung_cancer_classifier.joblib`
- metadados: `backend/model/lung_cancer_classifier.metadata.json`
- threshold selecionado na validacao: 0.15

Resumo do artefato exportado:

- modelo: `RandomForestClassifier`
- hiperparametros: `n_estimators=221, max_depth=27, min_samples_split=3, min_samples_leaf=2, max_features=0.8308`
- recall de validacao no threshold selecionado: 1.0
- metricas de teste com threshold produtivo:
 - accuracy: 0.5050
 - precision: 0.5050
 - recall: 1.0000
 - specificity: 0.0000
 - f1: 0.6711

Interpretacao tecnica:

- o threshold produtivo foi ajustado para maximizar recall na triagem;
- isso melhora a sensibilidade, mas praticamente elimina a especificidade;
- portanto, o artefato exportado e intencionalmente conservador para rastreo, e nao para confirmacao diagnostica.

9. Resultados Consolidados do AG de Imagem

Experimento	Fitness	Accuracy teste	Recall teste	Specificity teste	F1 teste	AUC teste
exp1	0.9781	0.9697	0.9881	0.9506	0.9708	0.9947
exp2	0.9630	0.9455	0.9881	0.9012	0.9486	0.9891
exp3	0.9696	0.9697	0.9524	0.9877	0.9697	0.9968

Melhor experimento de imagem:

- experimento vencedor: `exp1`
- fitness: 0.9781247099229556
- threshold selecionado: 0.10
- hiperparametros:
 - `learning_rate=0.000142`
 - `batch_size=16`
 - `frozen_epochs=3`
 - `fine_tune_epochs=1`
 - `dense_units=64`

- dropout_rate=0.4412
- use_class_weight=False
- unfreeze_layers=40

Artefatos exportados para a API:

- backend/model/best.keras
- backend/model/best_info.json
- backend/model/metrics.json

Resumo do artefato de imagem exportado:

- backbone: EfficientNetB0
- threshold: 0.10
- metricas de teste:
 - accuracy: 0.9697
 - precision: 0.9540
 - recall: 0.9881
 - specificity: 0.9506
 - f1: 0.9708
 - auc_roc: 0.9947

10. Integracao com LLMs

10.1 Abordagem de prompting

O arquivo `backend/llm/interpreter.py` define prompts estruturados para os dois fluxos:

- interpretacao tabular;
- interpretacao de imagem.

Os prompts compartilham as seguintes regras:

- formato obrigatorio com **Resumo**, **Risco**, **Justificativa**, **Recomendacao** e **Observacao**;
- proibicao de afirmar diagnostico fechado;
- obrigatoriedade de explicitar que a saida nao substitui avaliacao medica;
- linguagem objetiva e direcionada a profissionais de saude;
- recomendacao proporcional ao nivel de risco;
- proibicao de markdown e listas para manter padronizacao de saida.

No fluxo de imagem, o prompt ainda reforca que a interpretacao e baseada apenas na analise automatica da imagem e nao substitui laudo radiologico.

10.2 Limitacao de chamadas

O arquivo `backend/main.py` aplica controle de volume para chamadas da LLM:

- variavel de ambiente: `MAX_LLM_INTERPRETATIONS`
- valor padrao: 5

- regra: apenas os primeiros registros de cada lote recebem interpretação via Gemini;
- os demais recebem mensagem padrão informando a omissão para evitar excesso de chamadas.

Na avaliação offline em `avaliation/llm_evaluation.ipynb`, também foi adotada estratégia conservadora:

- `SAMPLE_SIZE = 8`
- `SECONDS_BETWEEN_CALLS = 15`
- uso de cache em `avaliation/cached_interpretations.json`

Essa combinação reduz risco de estouro da cota gratuita e melhora reprodutibilidade.

10.3 Tratamento de erros e resiliência

O cliente Gemini foi refinado com foco em resiliência operacional:

- inicialização lazy do cliente;
- retry exponencial com jitter para erros 429, `quota`, `resource_exhausted`, `rate limit` e `too many requests`;
- parâmetros configuráveis por ambiente:
 - `GEMINI_MODEL_NAME`
 - `GEMINI_MAX_RETRIES`
 - `GEMINI_RETRY_BASE_DELAY`
- fallback textual seguro quando:
 - a chave `GEMINI_API_KEY` não está configurada;
 - o pacote `google-genai` não está disponível;
 - a API externa falha após esgotar tentativas.

Com isso, a API continua respondendo mesmo sem dependência obrigatória da LLM.

11. Resultados da Avaliação de Qualidade das Interpretações da LLM

Os resultados desta seção foram consolidados a partir de `avaliation/llm_evaluation.ipynb`.

11.1 Propósito e Estrutura do Diretório de Avaliação (`/avaliation`)

Para atender ao critério de avaliação de qualidade das interpretações geradas pela LLM, estruturamos um ambiente de homologação e auditoria offline localizado na raiz do repositório sob a pasta `/avaliation`:
 * **`llm_evaluation.ipynb`**: Um notebook Jupyter interativo contendo a rotina de testes de qualidade. Ele processa uma amostra do dataset, envia os prompts estruturados à LLM, valida a presença de marcadores e gera relatórios de acerto.
 * **`cached_interpretations.json`**: Um banco de cache das respostas do Gemini, projetado para evitar requisições redundantes à API externa

(minimizando erros de rate-limiting) e permitindo que a banca execute o notebook com velocidade e reprodutibilidade, sem depender de uma chave de API ativa. * **Aviso de Arquitetura:** Esses componentes atuam puramente como ferramentas de qualidade offline e não têm dependência em tempo de execução no backend ou frontend.

11.2 Condições da avaliação

- amostra planejada: 8 casos;
- interpretações efetivamente avaliadas: 3;
- casos excluídos: 5, por fallback associado a erro de API/quota;
- motor avaliado: `gemini-2.5-flash`;
- critérios qualitativos manuais: `clareza`, `coerencia`, `seguranca_clinica`, `utilidade_clinica`, `padronizacao`.

11.3 Conformidade automática

- conformidade automática média: 96.3%
- melhor critério automático: `tem_secao_resumo` com 100%
- pior critério automático: `tem_disclaimer_medico` com 67%

Leitura:

- a LLM aderiu bem ao formato exigido e ao padrão estrutural dos prompts;
- a principal fragilidade automática identificada foi a presença inconsistente de disclaimer médico explícito.

11.4 Avaliação qualitativa manual

Critério	Média	Desvio padrão	N avaliado
<code>clareza</code>	5.00	0.00	3
<code>coerencia</code>	4.00	1.00	3
<code>seguranca_clinica</code>	4.67	0.58	3
<code>utilidade_clinica</code>	2.67	2.08	3
<code>padronizacao</code>	3.67	1.53	3

Resumo qualitativo:

- nota média geral: 4.00/5
- melhor critério: `clareza` (5.00)
- pior critério: `utilidade_clinica` (2.67)

Interpretação:

- a LLM foi consistente na clareza e, em geral, segura do ponto de vista clínico;

- o ponto mais fraco foi utilidade clinica pratica, indicando que parte das respostas ficou generica e pouco acionavel;
- os resultados sao promissores como apoio textual, mas ainda pedem refinamento de prompt para recomendacoes mais especificas e uniformes.

11.4 Limitacoes da avaliacao

- o tamanho efetivo da amostra foi pequeno (3 casos validos);
- houve impacto direto da cota gratuita da API, com 5 de 8 casos excluidos;
- portanto, os resultados devem ser lidos como uma avaliacao exploratoria inicial, e nao como validacao definitiva da qualidade da LLM.

12. Uso Produtivo na API

12.1 Tabular

O resultado produtivo do AG tabular entra na API por meio de:

- `backend/model/lung_cancer_classifier.joblib`
- carregamento em `backend/main.py`
- uso no endpoint `/analyze-tabular`

Ou seja, o `ga_optimization_results.json` e apenas relatorio, enquanto o `joblib` exportado e efetivamente consumido pela API.

12.2 Imagem

O resultado produtivo do AG de imagem entra na API por meio de:

- `backend/model/best.keras`
- carregamento resiliente em `backend/main.py`
- uso no endpoint `/analyze-images`

Assim, o AG de imagem tambem deixou de ser apenas analitico e passou a alimentar o fluxo produtivo do backend.

13. Testes e Validacao

Suíte automatizada:

- `tests/test_genetic_optimizer.py`
- `tests/test_genetic_optimizer_image.py`
- `tests/test_api.py`

Execucao validada:

```
python -m pytest -q
```

Resultado validado:

```
8 passed, 1 warning in 4.37s
```

14. Desafios Enfrentados e Soluções

Durante o desenvolvimento da Fase 2, a equipe enfrentou desafios técnicos e de engenharia críticos que exigiram soluções robustas:

14.1 Estouro de Limites de Quota na API do Gemini (Resource Exhausted)

- **Desafio:** A cota gratuita da API do Gemini (limites de requisições por minuto e por dia) causava o erro 429 `RESOURCE_EXHAUSTED` com frequência durante as análises de lotes de pacientes do CSV ou imagens múltiplas.
- **Solução:**
 1. **Controle de Vazão (Rate Limiting):** A API restringe chamadas externas ao Gemini para no máximo as **5 primeiras linhas/imagens** de cada lote.
 2. **Retry Exponencial com Jitter:** Implementação de uma política de tentativas automáticas no arquivo `backend/llm/interpreter.py` que aguarda de forma exponencial mais tempo com pequenas variações aleatórias de milissegundos (*jitter*) antes de re-tentar a chamada.
 3. **Mecanismo de Fallback:** Se a cota persistir esgotada após 3 tentativas, o sistema retorna um payload contendo as métricas de probabilidade locais calculadas pelos nossos modelos de Machine Learning acompanhado de um disclaimer informando a indisponibilidade momentânea do tradutor automático.

14.2 Discrepâncias de Dependências em Sistemas Operacionais Distintos

- **Desafio:** Integrantes da equipe utilizando macOS (especialmente com chips Apple Silicon M1/M2/M3/M4) e Windows encontravam incompatibilidades na compilação do TensorFlow e do opencv, inviabilizando a execução homogênea do algoritmo genético de imagem (`genetic_optimizer_image.py`).
- **Solução:**
 1. **Isolamento de Ambientes virtuais Dedicados:** Criamos um ambiente virtual específico para o fluxo de visão computacional (`.venv`), com um arquivo de requerimentos (`req_no_tf_mac.txt`) e instruções de instalação apartado das dependências normais do backend tabular.
 2. **Dockerização do Ambiente:** Uso de Dockerfiles específicos para rodar o pipeline de forma agnóstica a sistemas operacionais locais no backend e frontend.

14.3 Suporte Dual a Provedores de LLM (Gemini Developer API vs Google Vertex AI)


- **Desafio:** Em ambientes corporativos ou governamentais, o uso de chaves de API individuais (`GEMINI_API_KEY`) pode violar políticas de segurança ou governança de dados. Era necessário suportar credenciais integradas de nuvem via Vertex AI sem quebrar o código existente.
- **Solução:** Refatoramos a inicialização do cliente no arquivo `backend/llm/interpreter.py` para detectar automaticamente a variável `USE_VERTEX_AI`. Quando ativada, a API consome o cliente do Google Cloud Vertex AI com autenticação baseada em Application Default Credentials (ADC) ou contas de serviço, mantendo a assinatura e os prompts idênticos.

15. Arquitetura em Nuvem e Provisionamento (IaC)

Para implantar a aplicação de forma automatizada e escalável na nuvem, desenvolvemos arquivos de configuração **Terraform (IaC)** localizados no diretório `/terraform`.

15.1 Desenho da Arquitetura AWS

A arquitetura de implantação foi estruturada sob o ecossistema da **Amazon Web Services (AWS)** utilizando contêineres Fargate (sem servidor):



16. Como Reproduzir

16.1 Rodar o AG tabular

```
python train_model/genetic_optimizer.py
```

16.2 Rodar o AG de imagem

```
py -3.11 -m venv .venv  
.\.venv\bin\python -m pip install -r requirements.txt  
.\.venv\bin\python train_model\genetic_optimizer_image.py
```

16.3 Rodar os testes

```
python -m pytest -q
```

17. Proximos Passos Recomendados

1. recalibrar o threshold produtivo do modelo tabular para reduzir falsos positivos;
2. aumentar populacao e numero de geracoes do AG para melhor exploracao;
3. adicionar teste automatizado para o endpoint `/analyze-images`;
4. reforcar o prompt medico para elevar `utilidade_clinica` e padronizacao;
5. ampliar a avaliacao da LLM com amostra maior e menor dependencia da cota gratuita;
6. versionar artefatos e experimentos com rastreabilidade por hash e data.

18. Status Final

- AG tabular: concluido
- AG de imagem: concluido
- exportacao produtiva de artefatos: concluido
- retries Gemini e fallback: concluido
- testes automatizados: concluido
- avaliacao inicial da qualidade da LLM: concluida
- consolidacao documental em relatorio unico: concluida

Ultima atualizacao: 2026-07-12