

Análise de Dados - Câncer de Pulmão

Grupo 69

- Otoniel da Silva Isidoro - rm368069
- André Roberto Figueiró de Magalhães - rm365608
- Lucas de Melo Lima - rm373930
- Gustavo César de Souza - rm370800
- Thales Ernane de Souza - rm372083

Link do Vídeo: <https://www.youtube.com/watch?v=xxx>

Repositório GIT: <https://github.com/fiap-grupo-xpto/fiap-tech-challenge-fase-1>

Objetivo: Análise exploratória de dataset tabular de câncer de pulmão usando Python e Machine Learning

Dataset: [Kaggle – Lung Cancer Dataset](#) (sem PHI; respeitar licença).

Código-fonte: notebook `train_model/analise_cancer.ipynb`

Execução local: consultar o README.md e o Dockerfile da raiz do projeto

A solução foi organizada para atender aos requisitos de exploração, pré-processamento, modelagem, avaliação e explicabilidade.

Importação das Bibliotecas

Esta célula importa todas as bibliotecas necessárias para a análise: - **pandas**: Manipulação e análise de dados tabulares - **sklearn**: Algoritmos de machine learning (classificação, métricas, pré-processamento) - **matplotlib.pyplot**: Criação de gráficos básicos - **seaborn**: Visualizações estatísticas avançadas - **numpy**: Operações numéricas e arrays

```
[1]: # Importar bibliotecas necessárias
import warnings
import joblib
import pandas as pd # Para trabalhar com dados tabulares
import numpy as np # Transformação dos dados
import matplotlib.pyplot as plt # Gráficos
import seaborn as sns # Gráficos
import seaborn as sb # Gráficos
from sklearn.compose import ColumnTransformer
from sklearn.ensemble import RandomForestClassifier, ExtraTreesClassifier
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, classification_report, \
    confusion_matrix, ConfusionMatrixDisplay, f1_score, precision_score, \
    recall_score
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import LabelEncoder, OneHotEncoder, StandardScaler
```

```

from sklearn.model_selection import train_test_split, ParameterGrid

warnings.filterwarnings('ignore', category=RuntimeWarning)

try:
    import shap
except ModuleNotFoundError:
    shap = None

```

/Users/otoniel.isidoro/Documents/FIAP/TechChallenge/Tech_Challenge/.venv/lib/python3.9/site-packages/tqdm/auto.py:21: TqdmWarning: IProgress not found. Please update jupyter and ipywidgets. See https://ipywidgets.readthedocs.io/en/stable/user_install.html

```

from .autonotebook import tqdm as notebook_tqdm

```

Descrição do Dataset

Este dataset contém informações sobre fatores de risco associados ao câncer de pulmão. As colunas representam:

- **Gênero:** M (masculino), F (feminino)
- **Idade:** Idade do paciente
- **Fumar:** SIM=2, NÃO=1
- **Dedos amarelos:** SIM=2, NÃO=1
- **Ansiedade:** SIM=2, NÃO=1
- **Pressão dos pares:** SIM=2, NÃO=1
- **Doença crônica:** SIM=2, NÃO=1
- **Fadiga:** SIM=2, NÃO=1
- **Alergia:** SIM=2, NÃO=1
- **Chiado no peito:** SIM=2, NÃO=1
- **Álcool:** SIM=2, NÃO=1
- **Tosse:** SIM=2, NÃO=1
- **Falta de ar:** SIM=2, NÃO=1
- **Dificuldade para engolir:** SIM=2, NÃO=1
- **Dor no peito:** SIM=2, NÃO=1
- **Câncer de pulmão:** SIM, NÃO

1. Carregamento dos Dados

Esta seção carrega o dataset CSV e mostra os primeiros registros para entender a estrutura dos dados.

```

[2]: # Carregar os dados
dados = pd.read_csv('datasets/dataset.csv', sep=',')

# Compatibilizar nomes de colunas entre versões do dataset
dados.rename(columns={
    'YELLOW_FINGERS': 'YELLOW FINGERS',
    'PEER_PRESSURE': 'PEER PRESSURE',

```

```

    'CHRONIC_DISEASE': 'CHRONIC DISEASE',
    'ALCOHOL_CONSUMING': 'ALCOHOL CONSUMING',
    'SHORTNESS_OF_BREATH': 'SHORTNESS OF BREATH',
    'SWALLOWING_DIFFICULTY': 'SWALLOWING DIFFICULTY',
    'CHEST_PAIN': 'CHEST PAIN'
}, inplace=True)

# Visualizar os primeiros registros
dados.head()

```

```

[2]:  GENDER  AGE  SMOKING  YELLOW FINGERS  ANXIETY  PEER PRESSURE  \
0      M   65        1             1         1             2
1      F   55        1             2         2             1
2      F   78        2             2         1             1
3      M   60        2             1         1             1
4      F   80        1             1         2             1

      CHRONIC DISEASE  FATIGUE  ALLERGY  WHEEZING  ALCOHOL CONSUMING  COUGHING  \
0                   2         1         2         2                 2         2
1                   1         2         2         2                 1         1
2                   1         2         1         2                 1         1
3                   2         1         2         1                 1         2
4                   1         2         1         2                 1         1

      SHORTNESS OF BREATH  SWALLOWING DIFFICULTY  CHEST PAIN  LUNG_CANCER
0                   2                   2             1         NO
1                   1                   2             2         NO
2                   2                   1             1         YES
3                   1                   2             2         YES
4                   1                   1             2         NO

```

2. Exploração Inicial dos Dados

Esta seção realiza uma análise preliminar do dataset: - Verifica as dimensões (número de linhas e colunas) - Identifica valores nulos/missing - Mostra informações sobre tipos de dados - Estatísticas descritivas básicas

```

[3]: # Dimensões do dataset (linhas, colunas)
print("Dimensões do dataset:")
dados.shape

```

Dimensões do dataset:

```

[3]: (3000, 16)

```

```

[4]: print("\nValores nulos por coluna:")
dados.isnull().sum()

```

Valores nulos por coluna:

```
[4]: GENDER          0
      AGE            0
      SMOKING        0
      YELLOW FINGERS 0
      ANXIETY        0
      PEER PRESSURE  0
      CHRONIC DISEASE 0
      FATIGUE        0
      ALLERGY        0
      WHEEZING       0
      ALCOHOL CONSUMING 0
      COUGHING       0
      SHORTNESS OF BREATH 0
      SWALLOWING DIFFICULTY 0
      CHEST PAIN     0
      LUNG_CANCER    0
      dtype: int64
```

```
[5]: print("\nInformações do dataset:")
      dados.info()
```

Informações do dataset:

```
<class 'pandas.core.frame.DataFrame'>
```

RangeIndex: 3000 entries, 0 to 2999

Data columns (total 16 columns):

#	Column	Non-Null Count	Dtype
0	GENDER	3000 non-null	object
1	AGE	3000 non-null	int64
2	SMOKING	3000 non-null	int64
3	YELLOW FINGERS	3000 non-null	int64
4	ANXIETY	3000 non-null	int64
5	PEER PRESSURE	3000 non-null	int64
6	CHRONIC DISEASE	3000 non-null	int64
7	FATIGUE	3000 non-null	int64
8	ALLERGY	3000 non-null	int64
9	WHEEZING	3000 non-null	int64
10	ALCOHOL CONSUMING	3000 non-null	int64
11	COUGHING	3000 non-null	int64
12	SHORTNESS OF BREATH	3000 non-null	int64
13	SWALLOWING DIFFICULTY	3000 non-null	int64
14	CHEST PAIN	3000 non-null	int64
15	LUNG_CANCER	3000 non-null	object

dtypes: int64(14), object(2)

memory usage: 375.1+ KB

```
[6]: print("\nDescrição estatística dos dados numéricos:")
      dados.describe()
```

Descrição estatística dos dados numéricos:

```
[6]:
```

	AGE	SMOKING	YELLOW FINGERS	ANXIETY	PEER PRESSURE \
count	3000.000000	3000.000000	3000.000000	3000.000000	3000.000000
mean	55.169000	1.491000	1.514000	1.494000	1.499000
std	14.723746	0.500002	0.499887	0.500047	0.500082
min	30.000000	1.000000	1.000000	1.000000	1.000000
25%	42.000000	1.000000	1.000000	1.000000	1.000000
50%	55.000000	1.000000	2.000000	1.000000	1.000000
75%	68.000000	2.000000	2.000000	2.000000	2.000000
max	80.000000	2.000000	2.000000	2.000000	2.000000

	CHRONIC DISEASE	FATIGUE	ALLERGY	WHEEZING \
count	3000.000000	3000.000000	3000.000000	3000.000000
mean	1.509667	1.489667	1.506667	1.497333
std	0.499990	0.499977	0.500039	0.500076
min	1.000000	1.000000	1.000000	1.000000
25%	1.000000	1.000000	1.000000	1.000000
50%	2.000000	1.000000	2.000000	1.000000
75%	2.000000	2.000000	2.000000	2.000000
max	2.000000	2.000000	2.000000	2.000000

	ALCOHOL CONSUMING	COUGHING	SHORTNESS OF BREATH \
count	3000.000000	3000.000000	3000.000000
mean	1.491333	1.510667	1.488000
std	0.500008	0.499970	0.499939
min	1.000000	1.000000	1.000000
25%	1.000000	1.000000	1.000000
50%	1.000000	2.000000	1.000000
75%	2.000000	2.000000	2.000000
max	2.000000	2.000000	2.000000

	SWALLOWING DIFFICULTY	CHEST PAIN
count	3000.000000	3000.000000
mean	1.489667	1.498667
std	0.499977	0.500082
min	1.000000	1.000000
25%	1.000000	1.000000
50%	1.000000	1.000000
75%	2.000000	2.000000
max	2.000000	2.000000

```
[7]: print("\nNúmero de registros duplicados:")
      dados.duplicated().sum()
```

Número de registros duplicados:

```
[7]: 2
```

Limpeza de Dados

Esta seção trata da limpeza e preparação dos dados: - Identifica e remove registros duplicados - Garante qualidade dos dados para análise

```
[8]: dados.drop_duplicates(inplace=True)
```

```
[9]: print("\nContagem de valores únicos na coluna 'GENDER':")
      print("Para indentificar o número de registros masculinos e femininos:")
      dados['GENDER'].value_counts()
```

Contagem de valores únicos na coluna 'GENDER':

Para indentificar o número de registros masculinos e femininos:

```
[9]: GENDER
      M      1512
      F      1486
      Name: count, dtype: int64
```

```
[10]: print("\nContagem de valores únicos na coluna 'LUNG_CANCER':")
       print("Para identificar o número de registros com e sem câncer de pulmão:")
       dados['LUNG_CANCER'].value_counts()
```

Contagem de valores únicos na coluna 'LUNG_CANCER':

Para identificar o número de registros com e sem câncer de pulmão:

```
[10]: LUNG_CANCER
      YES      1517
      NO       1481
      Name: count, dtype: int64
```

```
[11]: print("Contagem dos valores únicos por idade:")
      dados['AGE'].value_counts()
```

Contagem dos valores únicos por idade:

```
[11]: AGE
      54      73
      75      71
      67      71
```

47	70
69	70
78	69
55	69
79	68
32	66
39	65
37	65
53	65
77	64
46	64
63	63
33	62
50	62
70	61
68	61
35	60
48	60
36	60
71	59
76	59
31	59
56	58
62	58
57	58
52	57
80	57
61	57
60	57
34	57
42	56
41	56
49	56
64	56
59	55
51	55
43	55
44	54
38	53
40	51
58	51
74	50
65	49
66	48
45	47
72	46
73	43

30 42
Name: count, dtype: int64

```
[12]: Total = len(dados)
temCancer = dados[dados["LUNG_CANCER"] == 'YES'].LUNG_CANCER.count()
naoTemCancer = dados[dados["LUNG_CANCER"] == 'NO'].LUNG_CANCER.count()

Percentual_tem_cancer = temCancer / Total

print("Total de dados: ", Total)
print("Total de pessoas que não tem cancer: ", naoTemCancer)
print("Total de pessoas que tem cancer: ", temCancer)
print("Percentual que tem cancer: ", (round(Percentual_tem_cancer, 2)*100), "%")
```


Total de dados: 2998
Total de pessoas que não tem cancer: 1481
Total de pessoas que tem cancer: 1517
Percentual que tem cancer: 51.0 %

Análise da Variável Alvo (Câncer de Pulmão)

Esta seção analisa a distribuição da variável dependente: - Contagem de casos positivos e negativos
- Cálculo de percentuais - Visualização com gráfico de pizza

```
[13]: print("\nDistribuição de câncer de pulmão:")
categororias = ["tem-cancer", "nao-tem-cancer"]
plt.pie(dados["LUNG_CANCER"].value_counts(), labels = categororias, autopct = '%.0f%%', explode= (0, 0.1), colors = ("g", "r"))
plt.show()
```

Distribuição de câncer de pulmão:



```
[14]: totalTemCancer = dados[dados["LUNG_CANCER"] == 'YES']
```

Análise dos Pacientes com Câncer

Esta seção foca nos pacientes diagnosticados com câncer: - Filtra apenas casos positivos - Mostra estatísticas descritivas dos fatores de risco - Cria visualizações dos padrões encontrados

```
[15]: totalTemCancer.head()
```

```
[15]:
```

	GENDER	AGE	SMOKING	YELLOW FINGERS	ANXIETY	PEER PRESSURE	\
2	F	78	2	2	1	1	
3	M	60	2	1	1	1	
5	F	58	1	1	1	2	
6	F	70	1	1	1	2	
11	F	60	2	2	1	1	

	CHRONIC DISEASE	FATIGUE	ALLERGY	WHEEZING	ALCOHOL CONSUMING	COUGHING	\
2		1	2	1		1	
3		2	1	2		1	
5		2	2	2		2	
6		2	1	2		2	
11		1	1	2		2	

	SHORTNESS OF BREATH	SWALLOWING DIFFICULTY	CHEST PAIN	LUNG_CANCER
--	---------------------	-----------------------	------------	-------------

2	2	1	1	YES
3	1	2	2	YES
5	1	1	2	YES
6	2	2	1	YES
11	1	2	1	YES

```
[16]: print("\nDescrição estatística dos registros com câncer de pulmão:")
totalTemCancer.describe().T
```

Descrição estatística dos registros com câncer de pulmão:

```
[16]:
```

	count	mean	std	min	25%	50%	75%	\
AGE	1517.0	54.652604	14.907541	30.0	41.0	54.0	68.0	
SMOKING	1517.0	1.498352	0.500162	1.0	1.0	1.0	2.0	
YELLOW FINGERS	1517.0	1.520765	0.499733	1.0	1.0	2.0	2.0	
ANXIETY	1517.0	1.487146	0.500000	1.0	1.0	1.0	2.0	
PEER PRESSURE	1517.0	1.486486	0.499982	1.0	1.0	1.0	2.0	
CHRONIC DISEASE	1517.0	1.504944	0.500140	1.0	1.0	2.0	2.0	
FATIGUE	1517.0	1.490442	0.500073	1.0	1.0	1.0	2.0	
ALLERGY	1517.0	1.510218	0.500060	1.0	1.0	2.0	2.0	
WHEEZING	1517.0	1.477917	0.499677	1.0	1.0	1.0	2.0	
ALCOHOL CONSUMING	1517.0	1.475939	0.499585	1.0	1.0	1.0	2.0	
COUGHING	1517.0	1.526697	0.499451	1.0	1.0	2.0	2.0	
SHORTNESS OF BREATH	1517.0	1.486486	0.499982	1.0	1.0	1.0	2.0	
SWALLOWING DIFFICULTY	1517.0	1.485827	0.499964	1.0	1.0	1.0	2.0	
CHEST PAIN	1517.0	1.499670	0.500165	1.0	1.0	1.0	2.0	

	max
AGE	80.0
SMOKING	2.0
YELLOW FINGERS	2.0
ANXIETY	2.0
PEER PRESSURE	2.0
CHRONIC DISEASE	2.0
FATIGUE	2.0
ALLERGY	2.0
WHEEZING	2.0
ALCOHOL CONSUMING	2.0
COUGHING	2.0
SHORTNESS OF BREATH	2.0
SWALLOWING DIFFICULTY	2.0
CHEST PAIN	2.0

```
[17]: plt.figure(figsize = (15,12))

plt.subplot(3,2,1)
```

```

sns.countplot(x = "SMOKING", hue="SMOKING", palette = "Paired", data = totalTemCancer, legend=False)

plt.subplot(3,2,2)
sns.countplot(x = "AGE", hue="AGE", palette = "Paired", data = totalTemCancer, legend=False)

plt.subplot(3,2,3)
sns.countplot(x = "CHRONIC DISEASE", hue="CHRONIC DISEASE", palette = "Paired", data = totalTemCancer, legend=False)


plt.subplot(3,2,4)
sns.countplot(x = "SHORTNESS OF BREATH", hue="SHORTNESS OF BREATH", palette = "Paired", data = totalTemCancer, legend=False)

plt.subplot(3,2,5)
sns.countplot(x = "ALCOHOL CONSUMING", hue="ALCOHOL CONSUMING", palette = "Paired", data = totalTemCancer, legend=False)

plt.subplot(3,2,6)
sns.countplot(x = "COUGHING", hue="COUGHING", palette = "Paired", data = totalTemCancer, legend=False)

```

[17]: <Axes: xlabel='COUGHING', ylabel='count'>




```
[18]: sb.boxplot(x='LUNG_CANCER', y='SMOKING', data=dados, palette='hls')
```

```
/var/folders/t4/3td2bmbs6h38d0yjvn8hwfjn_473md/T/ipykernel_74397/1999815708.py:1
: FutureWarning:
```

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.


```
sb.boxplot(x='LUNG_CANCER', y='SMOKING', data=dados, palette='hls')
```

```
[18]: <Axes: xlabel='LUNG_CANCER', ylabel='SMOKING'>
```



```
[19]: sb.boxplot(x=dados["AGE"])
```


```
[19]: <Axes: xlabel='AGE'>
```





Visualizações dos Fatores de Risco


Esta seção cria gráficos para entender os fatores de risco: - Gráficos de barras mostrando distribuição dos fatores - Histogramas para variáveis numéricas - Análise visual dos padrões nos pacientes com câncer


```
[20]: Colunas_Numericas = ["SMOKING", "AGE", "CHRONIC DISEASE", "SHORTNESS OF_
    ↳BREATH", "ALCOHOL CONSUMING", "COUGHING"]
for column in Colunas_Numericas:
    plt.figure()
    plot = totalTemCancer[column]
    sns.histplot(plot, bins=10, kde=True)
    plt.show()
```














```
[21]: dados_correlacao = dados.copy()

le_genero = LabelEncoder()
le_alvo = LabelEncoder()

dados_correlacao['GENDER'] = le_genero.fit_transform(dados_correlacao['GENDER'])
dados_correlacao['LUNG_CANCER'] = le_alvo.
    ↳fit_transform(dados_correlacao['LUNG_CANCER'])
```


Análise de Correlação

Esta seção analisa as relações entre os fatores de risco: - Calcula correlação de Pearson entre variáveis numéricas - Cria heatmap para visualizar associações - Ordena as variáveis pela força de correlação com LUNG_CANCER - Destaca visualmente quais fatores têm maior associação com o diagnóstico

```
[22]: # Calcular correlação apenas para colunas numéricas
correlation_matrix = dados_correlacao.select_dtypes(include=[np.number]).corr().
    ↳round(2)

fig, ax = plt.subplots(figsize=(12,10))
```

```
sns.heatmap(data=correlation_matrix, annot=True, linewidths=.5, ax=ax,
            cmap='coolwarm')
plt.title('Matriz de Correlação - Fatores de Risco para Câncer de Pulmão')
plt.show()
```



```
[23]: # Destacar a correlação das variáveis com a variável alvo
correlacao_com_cancer = correlation_matrix['LUNG_CANCER'].drop('LUNG_CANCER')
correlacao_com_cancer = correlacao_com_cancer.reindex(correlacao_com_cancer.
            abs().sort_values(ascending=False).index)


print('Correlação das variáveis com LUNG_CANCER:')
display(correlacao_com_cancer.to_frame(name='correlacao'))

plt.figure(figsize=(10, 6))
```

```
sns.barplot(x=correlacao_com_cancer.values, y=correlacao_com_cancer.index,
            hue=correlacao_com_cancer.index, palette='coolwarm', legend=False)
plt.title('Correlação das Variáveis com LUNG_CANCER')
plt.xlabel('Coeficiente de Correlação de Pearson')
plt.ylabel('Variáveis')
plt.axvline(0, color='black', linewidth=1)
plt.tight_layout()
plt.show()
```

Correlação das variáveis com LUNG_CANCER:

	correlacao
AGE	-0.04
WHEEZING	-0.04
ALCOHOL CONSUMING	-0.03
COUGHING	0.03
GENDER	-0.02
PEER PRESSURE	-0.02
SMOKING	0.01
YELLOW FINGERS	0.01
ANXIETY	-0.01
CHRONIC DISEASE	-0.01
ALLERGY	0.01
SWALLOWING DIFFICULTY	-0.01
FATIGUE	0.00
SHORTNESS OF BREATH	-0.00
CHEST PAIN	0.00



Preparação para Modelagem

Nesta etapa, os dados são preparados para o treinamento dos modelos: - Define-se a variável alvo e as variáveis explicativas; - Cria-se um pipeline de pré-processamento para variáveis categóricas e numéricas; - Realiza-se a separação entre **treino, validação e teste**, mantendo a proporção da classe alvo com estratificação.

O conjunto de treino será usado para ajustar os modelos, o conjunto de validação para comparar modelos e ajustar hiperparâmetros, e o conjunto de teste ficará reservado apenas para a avaliação final.

```
[24]: # Preparar os dados para a modelagem
dados_modelagem = dados.drop_duplicates().copy()

X = dados_modelagem.drop(columns=['LUNG_CANCER'])
y = dados_modelagem['LUNG_CANCER'].map({'NO': 0, 'YES': 1})

colunas_categoricas = X.select_dtypes(include=['object', 'string']).columns.
    ↪tolist()
colunas_numericas = [coluna for coluna in X.columns if coluna not in
    ↪colunas_categoricas]

preprocessador = ColumnTransformer(
    transformers=[
        ('categoricas', Pipeline([
            ('imputer', SimpleImputer(strategy='most_frequent')),
            ('onehot', OneHotEncoder(handle_unknown='ignore'))
        ]), colunas_categoricas),
        ('numericas', Pipeline([
            ('imputer', SimpleImputer(strategy='median')),
            ('scaler', StandardScaler())
        ]), colunas_numericas)
    ]
)

X_train_val, X_test, y_train_val, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
    stratify=y
)

X_train, X_val, y_train, y_val = train_test_split(
    X_train_val,
    y_train_val,
```

```

test_size=0.25,
random_state=42,
stratify=y_train_val
)

print(f'Formato de X_train: {X_train.shape}')
print(f'Formato de X_val: {X_val.shape}')
print(f'Formato de X_test: {X_test.shape}')

print('\nDistribuição da classe alvo no treino:')
print(y_train.value_counts(normalize=True).rename(index={0: 'NO', 1: 'YES'}))

print('\nDistribuição da classe alvo na validação:')
print(y_val.value_counts(normalize=True).rename(index={0: 'NO', 1: 'YES'}))

print('\nDistribuição da classe alvo no teste:')
print(y_test.value_counts(normalize=True).rename(index={0: 'NO', 1: 'YES'}))

```

Formato de X_train: (1798, 15)

Formato de X_val: (600, 15)

Formato de X_test: (600, 15)

Distribuição da classe alvo no treino:

LUNG_CANCER

YES 0.505562

NO 0.494438

Name: proportion, dtype: float64

Distribuição da classe alvo na validação:

LUNG_CANCER

YES 0.506667

NO 0.493333

Name: proportion, dtype: float64

Distribuição da classe alvo no teste:

LUNG_CANCER

YES 0.506667

NO 0.493333

Name: proportion, dtype: float64

Modelagem Preditiva

Foram escolhidas quatro técnicas de classificação para comparação porque este problema é tabular e pequeno, e modelos diferentes reagem de formas diferentes aos mesmos dados.

Como estamos falando de câncer, errar deixando passar um caso positivo é mais grave do que gerar um alerta extra. Por isso, nesta etapa, a prioridade clínica é detectar o máximo possível de casos suspeitos, mesmo que isso reduza a precisão e aumente os falsos positivos.

```
[25]: # Treinar diferentes modelos de classificação
modelos = {
    'Regressão Logística': LogisticRegression(max_iter=2000,
    ↳class_weight='balanced'),
    'KNN': KNeighborsClassifier(n_neighbors=7),
    'Random Forest': RandomForestClassifier(n_estimators=200, random_state=42,
    ↳class_weight='balanced', n_jobs=1),
    'Extra Trees': ExtraTreesClassifier(n_estimators=700, random_state=42,
    ↳class_weight='balanced', n_jobs=1)
}

modelos_treinados = {}
predicoes_validacao = {}
resultados_modelos = []

for nome_modelo, estimador in modelos.items():
    pipeline_modelo = Pipeline([
        ('preprocessador', preprocessador),
        ('classificador', estimador)
    ])

    pipeline_modelo.fit(X_train, y_train)

    y_pred = pipeline_modelo.predict(X_val)

    modelos_treinados[nome_modelo] = pipeline_modelo
    predicoes_validacao[nome_modelo] = y_pred

    resultados_modelos.append({
        'Modelo': nome_modelo,
        'Accuracy': accuracy_score(y_val, y_pred),
        'Recall': recall_score(y_val, y_pred, zero_division=0),
        'F1-score': f1_score(y_val, y_pred, zero_division=0)
    })

resultados_modelos_df = pd.DataFrame(resultados_modelos).sort_values(
    by=['Recall', 'F1-score', 'Accuracy'],
    ascending=False
)

display(resultados_modelos_df.round(3))

melhor_modelo_inicial = resultados_modelos_df.iloc[0]['Modelo']
print(f'Melhor modelo inicial pelo critério principal na validação (Recall):
↳{melhor_modelo_inicial}')
```

Modelo	Accuracy	Recall	F1-score
--------	----------	--------	----------

3	Extra Trees	0.513	0.549	0.534
1	KNN	0.518	0.530	0.527
2	Random Forest	0.503	0.523	0.516
0	Regressão Logística	0.493	0.470	0.485

Melhor modelo inicial pelo critério principal na validação (Recall): Extra Trees

Avaliação dos Modelos na Validação

As métricas foram escolhidas para refletir o problema real: - **Recall**: principal métrica aqui, porque mede quantos casos positivos o modelo consegue encontrar. - **F1-score**: ajuda a equilibrar recall e precisão. - **Accuracy**: aparece como referência, mas sozinha pode enganar quando o objetivo é não perder casos de câncer.

Nesta etapa, comparamos os modelos no conjunto de validação. O teste continua reservado para a avaliação final.

```
[26]: # Exibir relatório de classificação e matriz de confusão para cada modelo na
      ↪ validação
for nome_modelo, y_pred in predicoes_validacao.items():
    print(f'\nRelatório de classificação - {nome_modelo}')
    print(classification_report(
        y_val,
        y_pred,
        target_names=['NO', 'YES'],
        zero_division=0
    ))

    fig, ax = plt.subplots(figsize=(4, 4))
    matriz = confusion_matrix(y_val, y_pred)

    disp = ConfusionMatrixDisplay(
        confusion_matrix=matriz,
        display_labels=['NO', 'YES']
    )


    disp.plot(ax=ax, cmap='Blues', colorbar=False)
    ax.set_title(f'Matriz de Confusão - {nome_modelo} - Validação')
    plt.show()
```

Relatório de classificação - Regressão Logística


	precision	recall	f1-score	support
NO	0.49	0.52	0.50	296
YES	0.50	0.47	0.48	304
accuracy			0.49	600
macro avg	0.49	0.49	0.49	600

weighted avg	0.49	0.49	0.49	600
--------------	------	------	------	-----

Matriz de Confusão - Regressão Logística - Validação




Relatório de classificação - KNN					
	precision	recall	f1-score	support	
NO	0.51	0.51	0.51	296	
YES	0.52	0.53	0.53	304	
accuracy			0.52	600	
macro avg	0.52	0.52	0.52	600	
weighted avg	0.52	0.52	0.52	600	




Relatório de classificação - Random Forest					
	precision	recall	f1-score	support	
NO	0.50	0.48	0.49	296	
YES	0.51	0.52	0.52	304	
accuracy			0.50	600	
macro avg	0.50	0.50	0.50	600	
weighted avg	0.50	0.50	0.50	600	

Matriz de Confusão - Random Forest - Validação



Relatório de classificação - Extra Trees

	precision	recall	f1-score	support
NO	0.51	0.48	0.49	296
YES	0.52	0.55	0.53	304
accuracy			0.51	600
macro avg	0.51	0.51	0.51	600
weighted avg	0.51	0.51	0.51	600



Ajuste de Hiperparâmetros Básicos

Nesta etapa, foram testadas diferentes configurações para os modelos utilizados. O objetivo foi escolher a melhor combinação de hiperparâmetros com base no desempenho no conjunto de validação, sempre priorizando recall para reduzir a chance de falso negativo.

O conjunto de teste permaneceu separado e será utilizado apenas na avaliação final.

Como o problema é de triagem clínica, o limiar de decisão também será ajustado na validação para privilegiar a identificação de casos positivos.

```
[27]: # Ajuste de hiperparâmetros básicos usando o conjunto de validação
configuracoes_modelos = {
    'Regressão Logística': {
        'estimador': LogisticRegression(max_iter=2000, class_weight='balanced'),
        'parametros': {
            'classificador__C': [0.1, 1, 10],
            'classificador__solver': ['liblinear']
        }
    },
    'KNN': {
        'estimador': KNeighborsClassifier(),
        'parametros': {
            'classificador__n_neighbors': [3, 5, 7, 9],

```

```

        'classificador__weights': ['uniform', 'distance']
    },
    'Random Forest': {
        'estimador': RandomForestClassifier(random_state=42,
class_weight='balanced', n_jobs=1),
        'parametros': {
            'classificador__n_estimators': [100, 200],
            'classificador__max_depth': [None, 10],
            'classificador__min_samples_split': [2, 5]
        }
    },
    'Extra Trees': {
        'estimador': ExtraTreesClassifier(random_state=42,
class_weight='balanced', n_jobs=1),
        'parametros': {
            'classificador__n_estimators': [300, 700],
            'classificador__max_depth': [None, 10],
            'classificador__min_samples_leaf': [1, 2]
        }
    }
}

resultados_hiperparametros = []
modelos_ajustados = {}

melhor_modelo_final = None
melhor_modelo_nome = None
melhores_parametros = None
melhor_criterio = (-1, -1, -1)

for nome_modelo, configuracao in configuracoes_modelos.items():
    melhor_modelo_do_tipo = None
    melhor_parametros_do_tipo = None
    melhor_criterio_do_tipo = (-1, -1, -1)

    for parametros in ParameterGrid(configuracao['parametros']):
        pipeline_modelo = Pipeline([
            ('preprocessador', preprocessador),
            ('classificador', configuracao['estimador'])
        ])

        pipeline_modelo.set_params(**parametros)
        pipeline_modelo.fit(X_train, y_train)

        y_pred_val = pipeline_modelo.predict(X_val)

```

```

accuracy = accuracy_score(y_val, y_pred_val)
recall = recall_score(y_val, y_pred_val, zero_division=0)
f1 = f1_score(y_val, y_pred_val, zero_division=0)

criterio = (recall, f1, accuracy)

resultados_hiperparametros.append({
    'Modelo': nome_modelo,
    'Parâmetros': parametros,
    'Accuracy': accuracy,
    'Recall': recall,
    'F1-score': f1
})

if criterio > melhor_criterio_do_tipo:
    melhor_criterio_do_tipo = criterio
    melhor_modelo_do_tipo = pipeline_modelo
    melhor_parametros_do_tipo = parametros

if criterio > melhor_criterio:
    melhor_criterio = criterio
    melhor_modelo_final = pipeline_modelo
    melhor_modelo_nome = nome_modelo
    melhores_parametros = parametros

modelos_ajustados[nome_modelo] = melhor_modelo_do_tipo

resultados_hiperparametros_df = pd.DataFrame(resultados_hiperparametros).
    ↪sort_values(
        by=['Recall', 'F1-score', 'Accuracy'],
        ascending=False
    )

display(resultados_hiperparametros_df.round(3))

print(f'Melhor modelo após ajuste de hiperparâmetros: {melhor_modelo_nome}')
print('Melhores parâmetros:')
print(melhores_parametros)

```

	Modelo	Parâmetros \
19	Extra Trees	{'classificador__max_depth': None, 'classifica...
20	Extra Trees	{'classificador__max_depth': None, 'classifica...
6	KNN	{'classificador__n_neighbors': 5, 'classificad...
4	KNN	{'classificador__n_neighbors': 3, 'classificad...
23	Extra Trees	{'classificador__max_depth': 10, 'classificado...
3	KNN	{'classificador__n_neighbors': 3, 'classificad...
5	KNN	{'classificador__n_neighbors': 5, 'classificad...
16	Random Forest	{'classificador__max_depth': 10, 'classificado...

8	KNN	{'classificador__n_neighbors': 7, 'classificad...
24	Extra Trees	{'classificador__max_depth': 10, 'classificado...
7	KNN	{'classificador__n_neighbors': 7, 'classificad...
10	KNN	{'classificador__n_neighbors': 9, 'classificad...
11	Random Forest	{'classificador__max_depth': None, 'classifica...
12	Random Forest	{'classificador__max_depth': None, 'classifica...
13	Random Forest	{'classificador__max_depth': None, 'classifica...
21	Extra Trees	{'classificador__max_depth': None, 'classifica...
9	KNN	{'classificador__n_neighbors': 9, 'classificad...
14	Random Forest	{'classificador__max_depth': None, 'classifica...
15	Random Forest	{'classificador__max_depth': 10, 'classificado...
22	Extra Trees	{'classificador__max_depth': None, 'classifica...
17	Random Forest	{'classificador__max_depth': 10, 'classificado...
26	Extra Trees	{'classificador__max_depth': 10, 'classificado...
25	Extra Trees	{'classificador__max_depth': 10, 'classificado...
18	Random Forest	{'classificador__max_depth': 10, 'classificado...
0	Regressão Logística	{'classificador__C': 0.1, 'classificador__solv...
1	Regressão Logística	{'classificador__C': 1, 'classificador__solver...
2	Regressão Logística	{'classificador__C': 10, 'classificador__solve...

	Accuracy	Recall	F1-score
19	0.518	0.549	0.536
20	0.513	0.549	0.534
6	0.532	0.546	0.542
4	0.530	0.546	0.541
23	0.515	0.543	0.531
3	0.525	0.539	0.535
5	0.525	0.539	0.535
16	0.493	0.536	0.517
8	0.528	0.533	0.534
24	0.515	0.533	0.527
7	0.518	0.530	0.527
10	0.510	0.530	0.523
11	0.510	0.530	0.523
12	0.503	0.523	0.516
13	0.492	0.523	0.510
21	0.515	0.520	0.521
9	0.500	0.516	0.511
14	0.497	0.513	0.508
15	0.475	0.513	0.498
22	0.503	0.507	0.508
17	0.475	0.503	0.493
26	0.498	0.500	0.502
25	0.497	0.500	0.502
18	0.473	0.493	0.487
0	0.493	0.470	0.485
1	0.493	0.470	0.485
2	0.493	0.470	0.485

Melhor modelo após ajuste de hiperparâmetros: Extra Trees

Melhores parâmetros:

```
{'classificador__max_depth': None, 'classificador__min_samples_leaf': 1,
'classificador__n_estimators': 300}
```

Avaliação Final no Conjunto de Teste

Nesta etapa, o limiar de decisão é escolhido com foco clínico: primeiro garantir um recall alto na validação para evitar falso negativo, e só depois observar o impacto disso em falsos positivos.

Em linguagem simples, isso significa que o modelo pode disparar mais alertas do que o ideal, mas evita deixar passar casos suspeitos de câncer. O conjunto de teste é usado apenas aqui para medir esse comportamento em dados novos.

```
[28]: # Avaliação final do melhor modelo no conjunto de teste
y_pred_teste_padrao = melhor_modelo_final.predict(X_test)

limiar_recuperacao_minima = 0.99
melhor_limiar = 0.5
if hasattr(melhor_modelo_final.named_steps['classificador'], 'predict_proba'):
    probabilidades_validacao = melhor_modelo_final.predict_proba(X_val)[: , 1]
    resultados_limiar = []

    for limiar in np.linspace(0.15, 0.99, 99):
        y_pred_val_limiar = (probabilidades_validacao >= limiar).astype(int)
        tn, fp, fn, tp = confusion_matrix(y_val, y_pred_val_limiar).ravel()
        especificidade = tn / (tn + fp) if (tn + fp) > 0 else 0
        precisao = tp / (tp + fp) if (tp + fp) > 0 else 0
        recall = recall_score(y_val, y_pred_val_limiar, zero_division=0)

        resultados_limiar.append({
            'Limiar': limiar,
            'Accuracy': accuracy_score(y_val, y_pred_val_limiar),
            'Precision': precisao,
            'Recall': recall,
            'Specificity': especificidade,
            'False Negatives': fn,
            'False Positives': fp,
            'F1-score': f1_score(y_val, y_pred_val_limiar, zero_division=0)
        })

    resultados_limiar_df = pd.DataFrame(resultados_limiar)
    # Esta tabela é da validação, não do teste.
    candidatos = resultados_limiar_df[resultados_limiar_df['Recall'] >=
↳ limiar_recuperacao_minima]
    if candidatos.empty:
        candidatos = resultados_limiar_df.sort_values(
            by=['Recall', 'Specificity', 'Precision', 'Accuracy'],
```

```

        ascending=False
    )
    print('Nenhum limiar atingiu o recall mínimo definido; usando o melhor_
↪recall disponível.')
    else:
        candidatos = candidatos.sort_values(
            by=['Limiar', 'Recall', 'Specificity', 'Precision', 'Accuracy'],
            ascending=[True, False, False, False, False]
        )
        print(f'Selecionando o menor limiar com recall >=
↪{limiar_recuperacao_minima:.2f} na validação para reduzir ao máximo o risco_
↪de falso negativo.')

    resultados_limiar_df = resultados_limiar_df.sort_values(
        by=['Recall', 'Specificity', 'Precision', 'Accuracy'],
        ascending=False
    )
    melhor_limiar = float(candidatos.iloc[0]['Limiar'])

    display(resultados_limiar_df.head(10).round(3))
    print(f'Limiar escolhido na validação: {melhor_limiar:.2f} - este valor_
↪será aplicado ao teste.')

    y_pred_teste = (melhor_modelo_final.predict_proba(X_test)[: , 1] >=
↪melhor_limiar).astype(int)
else:
    y_pred_teste = y_pred_teste_padrao

def resumo_matriz(y_true, y_pred):
    tn, fp, fn, tp = confusion_matrix(y_true, y_pred).ravel()
    especificidade = tn / (tn + fp) if (tn + fp) > 0 else 0
    return tn, fp, fn, tp, especificidade

resumo_padrao = resumo_matriz(y_test, y_pred_teste_padrao)
resumo_validado = resumo_matriz(y_test, y_pred_teste)

print('A tabela abaixo compara o ponto de corte padrão com o ponto de corte_
↪escolhido na validação. A parte acima é a análise na validação; a parte_
↪abaixo é o resultado no teste.')

resultado_teste = pd.DataFrame([
    {
        'Cenário': 'Padrão 0.5',
        'Modelo final': melhor_modelo_nome,
        'Threshold': 0.50,
        'Accuracy': accuracy_score(y_test, y_pred_teste_padrao),
    }
])

```

```

        'Precision': precision_score(y_test, y_pred_teste_padrao,
↪zero_division=0),
        'Recall': recall_score(y_test, y_pred_teste_padrao, zero_division=0),
        'Specificity': resumo_padrao[4],
        'False Negatives': resumo_padrao[2],
        'False Positives': resumo_padrao[1],
        'F1-score': f1_score(y_test, y_pred_teste_padrao, zero_division=0)
    },
    {
        'Cenário': 'Threshold validado',
        'Modelo final': melhor_modelo_nome,
        'Threshold': melhor_limiar,
        'Accuracy': accuracy_score(y_test, y_pred_teste),
        'Precision': precision_score(y_test, y_pred_teste, zero_division=0),
        'Recall': recall_score(y_test, y_pred_teste, zero_division=0),
        'Specificity': resumo_validado[4],
        'False Negatives': resumo_validado[2],
        'False Positives': resumo_validado[1],
        'F1-score': f1_score(y_test, y_pred_teste, zero_division=0)
    }
])

display(resultado_teste.round(3))

print(f'Relatório de classificação do modelo final: {melhor_modelo_nome}↪
↪(threshold {melhor_limiar:.2f})')
print(classification_report(
    y_test,
    y_pred_teste,
    target_names=['NO', 'YES'],
    zero_division=0
))

fn = confusion_matrix(y_test, y_pred_teste).ravel()[2]
print(f'Casos positivos que o modelo deixou passar (falsos negativos): {fn}')

matriz_padrao = confusion_matrix(y_test, y_pred_teste_padrao)
matriz_validada = confusion_matrix(y_test, y_pred_teste)

fig, axes = plt.subplots(1, 2, figsize=(10, 4))

disp_padrao = ConfusionMatrixDisplay(
    confusion_matrix=matriz_padrao,
    display_labels=['NO', 'YES']
)
disp_padrao.plot(ax=axes[0], cmap='Blues', colorbar=False)
axes[0].set_title(f'Matriz - Threshold 0.50 - {melhor_modelo_nome}')

```

```

disp_validada = ConfusionMatrixDisplay(
    confusion_matrix=matriz_validada,
    display_labels=['NO', 'YES']
)
disp_validada.plot(ax=axes[1], cmap='Blues', colorbar=False)
axes[1].set_title(f'Matriz - Threshold {melhor_limiar:.2f} - \
↳{melhor_modelo_nome}')

plt.tight_layout()
plt.show()

```

Selecionando o menor limiar com recall ≥ 0.99 na validação para reduzir ao máximo o risco de falso negativo.

	Limiar	Accuracy	Precision	Recall	Specificity	False Negatives	\
0	0.150	0.505	0.506	0.997	0.000	1	
1	0.159	0.505	0.506	0.997	0.000	1	
2	0.167	0.505	0.506	0.997	0.000	1	
3	0.176	0.505	0.506	0.997	0.000	1	
4	0.184	0.505	0.506	0.997	0.000	1	
5	0.193	0.505	0.506	0.997	0.000	1	
6	0.201	0.505	0.506	0.997	0.000	1	
7	0.210	0.505	0.506	0.997	0.000	1	
9	0.227	0.505	0.506	0.993	0.003	2	
8	0.219	0.503	0.505	0.993	0.000	2	

	False Positives	F1-score
0	296	0.671
1	296	0.671
2	296	0.671
3	296	0.671
4	296	0.671
5	296	0.671
6	296	0.671
7	296	0.671
9	295	0.670
8	296	0.670

Limiar escolhido na validação: 0.15 - este valor será aplicado ao teste.
A tabela abaixo compara o ponto de corte padrão com o ponto de corte escolhido na validação. A parte acima é a análise na validação; a parte abaixo é o resultado no teste.

	Cenário	Modelo final	Threshold	Accuracy	Precision	Recall	\
0	Padrão	0.5 Extra Trees	0.50	0.505	0.512	0.484	
1	Threshold validado	Extra Trees	0.15	0.507	0.507	1.000	



Specificity	False Negatives	False Positives	F1-score
-------------	-----------------	-----------------	----------

0	0.527	157	140	0.497
1	0.000	0	296	0.673

Relatório de classificação do modelo final: Extra Trees (threshold 0.15)

	precision	recall	f1-score	support
NO	0.00	0.00	0.00	296
YES	0.51	1.00	0.67	304
accuracy			0.51	600
macro avg	0.25	0.50	0.34	600
weighted avg	0.26	0.51	0.34	600

Casos positivos que o modelo deixou passar (falsos negativos): 0



Produtização do Modelo

Depois de treinado e avaliado, o modelo é salvo em um arquivo de artefato para poder ser carregado depois pelo backend sem precisar treinar tudo novamente.

O artefato salva o pipeline completo, que inclui pré-processamento, modelo final e o limiar operacional escolhido na validação.

```
[29]: # Salvar o pipeline treinado para uso posterior no backend
import json
from pathlib import Path

caminhos_saida = [Path("backend/model"), Path("../backend/model")]
pasta_saida = next((caminho for caminho in caminhos_saida if caminho.parent.
    exists()), Path("backend/model"))
pasta_saida.mkdir(parents=True, exist_ok=True)
```

```

artefato_modelo = {
    "pipeline": melhor_modelo_final,
    "threshold": melhor_limiar,
    "model_name": melhor_modelo_nome,
    "feature_columns": X.columns.tolist(),
    "selected_params": melhores_parametros,
    "validation_summary": resultado_teste.to_dict(orient="records"),
    "target_mapping": {"NO": 0, "YES": 1}
}

artefato_path = pasta_saida / "lung_cancer_classifier.joblib"
joblib.dump(artefato_modelo, artefato_path)

metadata_path = pasta_saida / "lung_cancer_classifier.metadata.json"
metadata_path.write_text(json.dumps({
    "model_name": melhor_modelo_nome,
    "threshold": melhor_limiar,
    "feature_columns": X.columns.tolist(),
    "selected_params": melhores_parametros,
    "validation_summary": resultado_teste.to_dict(orient="records")
}, ensure_ascii=False, indent=2), encoding="utf-8")

print(f"Artefato salvo em: {artefato_path}")
print(f"Metadados salvos em: {metadata_path}")

```

Artefato salvo em: ../backend/model/lung_cancer_classifier.joblib
 Metadados salvos em: ../backend/model/lung_cancer_classifier.metadata.json

Explicabilidade

Para interpretação das previsões, foi utilizada a Random Forest como modelo explicativo: - **Feature importance** para identificar as variáveis mais relevantes globalmente - **SHAP** para medir a contribuição média das variáveis nas previsões

```

[30]: # Importância das variáveis com o melhor modelo do tipo árvore
if hasattr(melhor_modelo_final.named_steps['classificador'],
    ↪ 'feature_importances_'):
    modelo_explicativo = melhor_modelo_final
else:
    modelo_explicativo = modelos_ajustados.get('Extra Trees', modelos_ajustados.
    ↪ get('Random Forest', modelos_treinados['Random Forest']))

nomes_features = modelo_explicativo.named_steps['preprocessador'].
    ↪ get_feature_names_out()
importancias = modelo_explicativo.named_steps['classificador'].
    ↪ feature_importances_

```

```

importancias_df = pd.DataFrame({
    'Variável': nomes_features,
    'Importância': importancias
}).sort_values(by='Importância', ascending=False).head(10)


display(importancias_df)

plt.figure(figsize=(10, 6))
sns.barplot(
    data=importancias_df,
    x='Importância',
    y='Variável',
    hue='Variável',
    palette='viridis',
    legend=False
)

plt.title('Top 10 Variáveis Mais Importantes - Modelo Explicativo')
plt.xlabel('Importância')
plt.ylabel('Variáveis')
plt.tight_layout()
plt.show()

```

	Variável	Importância
2	numericas__AGE	0.108247
15	numericas__CHEST PAIN	0.075931
12	numericas__COUGHING	0.075329
4	numericas__YELLOW FINGERS	0.070403
8	numericas__FATIGUE	0.068725
14	numericas__SWALLOWING DIFFICULTY	0.068532
10	numericas__WHEEZING	0.067728
13	numericas__SHORTNESS OF BREATH	0.066390
6	numericas__PEER PRESSURE	0.065547
3	numericas__SMOKING	0.065388



```
[31]: # Explicabilidade com SHAP usando o conjunto de validação
if shap is None:
    print('SHAP não está instalado no ambiente atual.')
else:
    X_val_transformado = modelo_explicativo.named_steps['preprocessador'].
    ↪transform(X_val)

    if hasattr(X_val_transformado, 'toarray'):
        X_val_transformado = X_val_transformado.toarray()

    amostra_validacao = X_val_transformado[: min(200, len(X_val_transformado))]

    explicador = shap.TreeExplainer(modelo_explicativo.
    ↪named_steps['classificador'])
    shap_values = explicador.shap_values(amostra_validacao)

    if isinstance(shap_values, list):
        shap_classe_positiva = shap_values[1]
    elif getattr(shap_values, 'ndim', 0) == 3:
        shap_classe_positiva = shap_values[:, :, 1]
    else:
        shap_classe_positiva = shap_values

    shap_importancia_df = pd.DataFrame({
        'Variável': nomes_features,
```

```

    'Impacto médio SHAP': np.abs(shap_classe_positiva).mean(axis=0)
}).sort_values(by='Impacto médio SHAP', ascending=False).head(10)


display(shap_importancia_df)

plt.figure(figsize=(10, 6))
sns.barplot(
    data=shap_importancia_df,
    x='Impacto médio SHAP',
    y='Variável',
    hue='Variável',
    palette='magma',
    legend=False
)

plt.title('Top 10 Variáveis por Impacto Médio SHAP')
plt.xlabel('Impacto médio absoluto SHAP')
plt.ylabel('Variáveis')
plt.tight_layout()
plt.show()

```

	Variável	Impacto médio SHAP
11	numericas__ALCOHOL CONSUMING	0.027265
5	numericas__ANXIETY	0.021853
9	numericas__ALLERGY	0.017633
10	numericas__WHEEZING	0.016260
8	numericas__FATIGUE	0.015293
13	numericas__SHORTNESS OF BREATH	0.014789
4	numericas__YELLOW FINGERS	0.014581
14	numericas__SWALLOWING DIFFICULTY	0.014137
7	numericas__CHRONIC DISEASE	0.014034
12	numericas__COUGHING	0.013196



Conclusões Críticas

Cobrimos o fluxo técnico esperado para um projeto de classificação com Machine Learning: exploração dos dados, limpeza, pré-processamento, análise de correlação, separação entre treino, validação e teste, treinamento com múltiplos modelos, ajuste de hiperparâmetros, avaliação final e explicabilidade.

A comparação entre **Regressão Logística**, **KNN**, **Random Forest** e **Extra Trees** mostrou que este dataset tem sinal preditivo limitado. Em termos simples, os dados não se separam com clareza: pacientes com e sem câncer parecem muito parecidos para o modelo. Por isso, a **accuracy** não sobe muito e não deve ser a métrica principal.

Neste problema, o erro mais perigoso é o **falso negativo**: quando o modelo diz que a pessoa não tem câncer, mas ela tem. Em saúde, isso é mais grave do que um falso positivo, porque pode atrasar exame, encaminhamento e tratamento. Por isso, as decisões do notebook priorizam **recall** e a contagem de falsos negativos.

O ajuste de limiar foi feito para manter uma sensibilidade alta na validação. Em linguagem simples: o modelo foi configurado para “acender o alerta” com mais facilidade, porque é melhor mandar alguns casos a mais para revisão do que deixar um caso suspeito passar despercebido. Ao baixar um pouco o limiar, dá para reduzir os falsos negativos, mas isso também aumenta os falsos positivos. Em triagem médica, esse é o trade-off esperado.

Mesmo assim, este dataset tem limitações importantes. Ele usa variáveis simples de questionário, quase todas binárias, sem exames laboratoriais, sem imagem, sem histórico clínico detalhado e sem sinais mais ricos que normalmente ajudam um médico a distinguir melhor os casos. Por isso, o modelo consegue apoiar a triagem, mas não consegue atingir uma precisão muito alta como se estivesse trabalhando com dados clínicos mais completos.

O modelo pode ser usado na prática como uma camada de **pré-triagem** para chamar atenção da equipe médica para casos que merecem revisão. Ele não deve ser tratado como diagnóstico final. A decisão clínica precisa continuar com o(a) médico(a), que deve considerar contexto, exame físico, histórico e confirmação diagnóstica antes de qualquer conduta.

As etapas de explicabilidade com **feature importance** e **SHAP** ajudam a mostrar quais variáveis mais influenciam a previsão. Isso melhora a auditabilidade e a discussão técnica do modelo no relatório final, mas não elimina o risco de viés, erro de generalização ou limitação do conjunto de dados.